


Redes Neurais

Aula de exercícios



1

Redes RBF



Relembrando conceitos: **RBF**

- **Modelo neural multicamadas, capaz de aprender padrões complexos e resolver problemas não-linearmente separáveis**
- **Treinamento em dois estágios:**
 - Primeiro, são determinados os parâmetros das funções de base (não linear, não-supervisionado).
 - Segundo, são determinados os pesos da camada de saída (problema linear).




Relembrando conceitos: **RBF**

● A arquitetura em três camadas:

- Camada de entrada, constituída de nós sensoriais.
- Camada intermediária (única) que aplica uma transformação não-linear do espaço de entrada para o espaço oculto (alta dimensionalidade);
- Camada de saída, que fornece a resposta da rede ao padrão apresentado. A transformação do espaço das unidades ocultas para o espaço de saída é linear.



Relembrando conceitos: **RBF**





Relembrando conceitos: **RBF**

● Teoria matemática:

$$h(x) = \sum_{i=0}^N w_i \cdot \phi(x)$$

em que


$$\phi(x) = e^{\frac{-||x-c_i||}{2\sigma^2}},$$

logo,

$$\vec{\phi} \vec{w} = \vec{y} \therefore \vec{w} = \vec{\phi}^{-1} \vec{y}$$




Exercício: XOR com RBF



x_1	x_2	w_0	l_1	l_2	Y
0	0				0
0	1				1
1	0				1
1	1				0



Exercício: XOR com RBF




2


Redes SOM (SOFM)




Relembrando conceitos: **SOM**

- **Método para reduzir dimensionalidade:**
Provê visões em dimensionalidade menor (geralmente 2-D) de espaços de dados com dimensionalidades mais altas.








0

200

400

600

800




1000

1200

1400

1600

1800



2000

2200

2400

10000

Blue

Purple

Green

Yellow

Orange


Red




Relembrando conceitos: **SOM**

● Topologias

Mapas de nós, geralmente, em um espaço bidimensional com arranjo retangular ou hexagonal.



Rectangular



Hexagonal



Relembrando conceitos: SOM

● Organização

- Cada neurônio (ou nó) é associado a um vetor de pesos.
- O tamanho do vetor de pesos corresponde à dimensão da entrada.
- O vetor de pesos é, geralmente, inicializado aleatoriamente.

● Aprendizado não-supervisionado:

- Realizado em dois passos:
 1. Mapear o conjunto de treino - processo competitivo.
 2. Classificar os novos vetores de entrada.
- Necessário um conjunto de entrada próximo o bastante do mapeamento que se deseja realizar.



Relembrando conceitos: **SOM**

● Algoritmo básico

1. Inicializar os vetores de pesos, \vec{W}_j , dos nós do mapa;
2. Para cada vetor de entrada $\vec{X}(n)$, faça:
 1. Obter a similaridade (distância euclidiana) entre cada nó do mapa $\vec{W}_j(n)$ e $\vec{X}(n)$;
 2. Determinar o nó que produz a menor distância (BMU);
 3. Atualize os nós da vizinhança de BMU (incluindo o próprio BMU) de acordo com:

$$\vec{W}_j(n+1) = \vec{W}_j(n) + \eta(n) \cdot \phi_{i,j}(n) \cdot (\vec{X}(n) - \vec{W}_j(n)),$$

em que

$\eta(n)$ é o fator de aprendizado, decrementado a cada iteração n ;





$\phi_{i,j}(n)$ é a função de vizinhança, que determina a distância entre o nó atual, j , e o BMU, i .

$$\phi_{i,j}(n) = e^{\frac{-d_{ij}}{2\sigma^2}}$$



Exercício: SOM

Dadas coordenadas em um plano com valores entre 0 e 1, em que $X_1 = 0$ indica extremo sul e $X_2 = 0$ indica extremo oeste, classifique um conjunto de entradas como centro, sudeste, sudoeste, nordeste e noroeste.



$\vec{w}_A, \vec{w}_B, \vec{w}_C, \vec{w}_D?$